



INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

ACTIVIDAD

Práctica 2.- Modelo Entidad-Relación-Extendido

BASE DE DATOS

Profesor: Gabriel Hurtado Avilés

Alumnos:

Sánchez Rodriguez Santiago

Casasola Avalos Diana Valeria

Grupo: 3CV2

Ejercicio 3. Lectura y resumen de tres artículos

Artículo 1. Datos sísmicos.

1. Qué problema aborda y por qué importa.

El problema que aborda es lo difícil que llega a ser comprender y analizar la información sobre sismos en México, y se crea por el Servicio Sismológico Nacional (SSN). Porque esta institución guarda registros desde 1900, estos datos de normal son muy técnicos, no tanto de manera visual y con un poquito de complejidad de manejar para personas que no conocen al respecto.

Este problema tiene más relevancia en México porque se está en una zona que es de alta actividad sísmica que son el Cinturón de Fuego del Pacífico y con cinco placas tectónicas interactuando en su territorio, que vendría poniendo cerca del 70% del país a riesgos sísmicos, afectando a zonas muy pobladas. Lo que busca es hacer más fácil el acceso a la comprensión de estos datos porque es algo de mucha importancia para la gestión gubernamental, la educación, el conocimiento del público y para la investigación científica enfocada en que se prevengan los desastres.

2. De dónde provienen los datos, en qué formato estaban y qué tuvo que hacerse para poder usarlos.

Los datos los consigue de dos principales fuentes que son el Servicio Sismológico Nacional que tiene datos desde 1900, luego el Instituto Nacional de Estadística y Geografía para la información sobre la población, las viviendas y los censos económicos. Y desde un inicio se obtuvieron en formato CSV desde sus sitios oficiales del SSN y INEGI.

Para todo el proceso de la preparación primero se hizo una validación y limpieza con un programa de Python que desarrollaron para leer los archivos CSV y ver si tenía campos vacíos, coordenadas erróneas o información incompatibles para que quitara los errores o cosas sin valor. Después ya que el programa de Python creo un código SQL y creo los datos ya validados esos se cargaron a la base de datos PostgreSQL como si fuera un almacén de datos para poder organizar la información si es sísmica, demográfica o económica.

3. Cómo se modeló la información: qué entidades o dimensiones se identificaron, qué hechos se miden y cómo se relacionan.

Se modelo en un almacén de datos que se hizo dentro de PostgreSQL y algunas entidades y entidades que identifique, fueron que se integraron dimensiones temporales como el año, mes, o la fecha, también dimensiones espaciales o geográficas como en los estados, localidades, coordenadas exactas y mapas cartográficos, de igual forma dimensiones demográficas en la población total y habitantes que existen por región, y por último dimensiones económicas en la producción de censos económicos.

Los hechos que llegan a medir y registrar son métricas claves de los eventos sísmicos como su magnitud, su profundidad y sus ubicaciones geográficas de los epicentros, que hacen combinación con métricas socioeconómicas como en la población afectada y la actividad

económica de la zona de riesgo.

Y para las relaciones el sistema vincula una ubicación espacial y sus magnitudes de los sismos con sus fuentes de información de población y economía del INEGI lo que le permite calcular que tan cerca es el epicentro a zonas muy pobladas y sacar un impacto aproximado en esos sectores.

4. Qué preguntas concretas puede responder el sistema resultante.

Algunas preguntas que llega a responder el sistema son:

-¿Cuál es la distribución de magnitudes y profundidades de los sismos en suceden en un estado en partículas durante un determinado periodo de tiempo?

-¿Qué poblaciones o localidades que sean mayor a 50000 habitantes se encuentran cerca de los epicentros de los sismos con ciertas magnitudes que sean superiores al promedio?

-¿Cuál será la población que será potencialmente mas afectada y cual será un estimado de su impacto económico a lo largo de un año en particular?

-¿Cuáles son las regiones con actividades sísmicas mas recurrentes a lo largo de 125 años en registros disponibles y como a sido su alcance en sus mapas de calor ante esos eventos?

5. Qué limitaciones reconocen los autores y qué trabajo futuro proponen.

Pues algunas limitaciones que llegan a mostrar los autores son que la implementación y el despliegue de los sistemas bases de datos y también los servidores web llegan a ser complicados de usar para los usuarios con poco casi nulo conocimiento de las herramientas que se van a ocupar, para poder “mitigar” esos problemas se recurrió al uso de contenedores virtuales con Docker Compose para facilitar la ejecución con comandos que llegan a ser muy simples.

Y para un trabajado futuro se propone habilitar visualizaciones interactivas en 3D, incorporar nuevas fuentes de datos que sean oficiales e integrar un sistema con plataformas que sean de alerta temprana.

Artículo 2. Consumo de agua en la Ciudad de México.

1. Qué problema aborda y por qué importa.

Un problema que llegan a abordar es las crisis de México en gestiones del agua como la sobreexplotación de acuíferos , las fugas de agua o el simple pero rápido crecimiento de la población en México, y anqué se tienen muchos datos abiertos de parte de SACMEX, el problema es que estos son pocos accesibles o simplemente no tienen herramientas de consulta, por lo tanto se limita mucho el uso que se pueden dar para tomar decisiones de acuerdo con las evidencias.

Su importancia recae en que al transformar un conjunto de datos que están dispersos en un solo repositorio que será dimensional y consultable va a ayudar a realizar varios diagnósticos como por ejemplo urbanos, investigaciones académicas, periodismo o el monitoreo ciudadano de una manera transparente sobre cómo es la gestión del recurso hídrico.

2. De dónde provienen los datos, en qué formato estaban y qué tuvo que hacerse para poder usarlos.

Los datos provienen de el portal de datos abiertos de la Ciudad de México que fue publicado por SACMEX más específicamente del Consumo Agua del primer semestre de 2019 que muestra los primeros tres bimestres del año 2019 y también se agregaron meteorologías de Open-Meteo y OpenStreetMap, todos los datos estaban en archivos de formato CSV.

Y para poder utilizar estos datos primero se uso un proceso de extracción, transformación y uno de carga ETL en cuatro fases, primero se extrajo los archivos CSV originales, después paso por un proceso donde se validaban y limpiaban los datos, determinando si tienen campos vacíos o coordenadas inconscientes gracias a esto se eliminaron 216 registros que tenían etiquetas territoriales que no coincidían, y logrando conseguir 70,886 registros limpios, para la siguiente fase se hizo cargas por etapas de manera intermedia para ir poblando las dimensiones del modelo y por ultimo se coloco el poblamiento en tablas de hechos con uniones estrictas.

3. Cómo se modeló la información: qué entidades o dimensiones se identificaron, qué hechos se miden y cómo se relacionan.

Se uso un modelo de esquema en estrella que esta dentro de una arquitectura de capas encima del PostgreSQL. Algunas de las dimensiones que se identificaron fueron por ejemplo:

-dim_tiempo: Contiene fechas, los años y los bimestres.

-dim_ubicacion: Contiene las alcaldías, las colonias , las latitudes y las longitudes.

-dim_indice_des: Contiene los niveles de desarrollo socioeconómico dividiéndolos en 4 niveles: Alto, Medio, Bajo y Popular.

Los hechos que se identificaron que llegan a medir son:

- fact_consumo_agua: Mide que tanto fue el consumo de agua por manzana o unidad de lectura según un periodo de facturación

- fact_clima: Va almacenando las series meteorológicas diarias que se van presentando.

Estas dos tablas de hechos se comparten y se vinculan a través de las dimensiones temporales y espaciales, esto permite que se puedan hacer consultas de manera cruzada y además su modelo relacional se proyecta de manera declarativa por mapeos R2RML hacia un grafo RDF usando vocabulario RDF Data Cube.

4. Qué preguntas concretas puede responder el sistema resultante.

Algunas preguntas que responde el sistema son:

-¿Cuál es el consumo promedio o total de agua desagregado por cada alcaldía y colonia?

-¿Cómo va variando el consumo de agua entre distintos bimestres?

-¿Qué zonas presentan comportamientos de consumo que sean atípicos comparados con el resto de su demarcación?

-¿Qué colonias están próximas geográficamente hablando como por ejemplo en una zona menor al 1.5km mediante la proximidad del grafo a una zona seleccionada y cuáles serán sus niveles de consumo?

5. Qué limitaciones reconocen los autores y qué trabajo futuro proponen.

Algunas limitaciones que muestran en su trabajo es que tiene n alcance temporal, porque sus datos corresponden únicamente a tres bimestres de un solo año esto hace que la variación estacional sea muy limitada y no permitiendo que se pueda estimar a un largo plazo, también los módulos de anomalías no son exactos porque se sacaron con perturbaciones sintéticas y no con datos reales de campo, las representaciones de las colonias están mediante punto y no polígonos completos entonces las relaciones topológicas no aplicarían de forma nativa y también que la relación que existe entre el índice de desarrollo y el consumo de agua es solo descriptiva y no atribuye para hacer mecanismos socioeconómicos de manera casual.

Y el trabajo a futuro que tienen propuesto es que quieren materializar los grafos en un almacén de tripletas con un punto de acceso público, también el remplazar las aproximaciones por centroides para lograr predicciones topológicas exactas, también reevaluar el modelo de detección de anomalías para cuando se dispondrá de datos reales sobre fugas y también transferir las metodologías a otros dominios de datos urbanos abiertos como en movilidad, la calidad del aire y los riesgos sísmicos.

Artículo 3. Obra pública municipal.

1. Qué problema aborda y por qué importa.

El tema que se aborda es la falta de transparencia que existe en la gestión de obras públicas que sean a nivel municipales y con información sobre administración de archivos distribuidos, hojas de calculo o en sistemas aislados, todo esto impidiendo un análisis histórico, o una detección de retrasos y también la participación ciudadana informada. Su importancia recae en que se permita ofrecer una supervisión transparente, auditable y orientada a los ciudadanos sobre las obras públicas, para evitar los altos costos de infraestructura.

2. De dónde provienen los datos, en qué formato estaban y qué tuvo que hacerse para poder usarlos.

Todos los datos que se llegan a usar fueron datos sintéticos generados por simulación con un total de 1,247 obras publicas y 55 comunidades, y en cambio la evidencia de reportes fotográficos y documentos de PDF se almacenan en un repositorio de objetos con Cloudflare R2. Y para su uso el almacén de datos se alimenta desde un esquema operacional con activadores de bases de datos que sincronizan y registran automáticamente los eventos en

tablas de hechos de auditorías.

3. Cómo se modeló la información: qué entidades o dimensiones se identificaron, qué hechos se miden y cómo se relacionan.

El modelo que se implementó en el artículo fue un esquema de estrella en el cual se encontraron las siguientes dimensiones:

Cambio lento tipo 2:

- dim_work: Guarda la trazabilidad histórica de los datos y atributos de cada obra pública.
- dim_region: Crea un historial de las regiones evitando que cambios territoriales o de nombres alteren las series históricas
- dim_company: Preserva un historial de empresas asegurando que los avances o incidencias se pasen correctamente a un contratista aunque existan reasignaciones.
- dim_staff: Anota los cambios del personal o funcionario a cargo.
- dim_budget: Son los datos de los presupuestos asignados, permitiendo a los auditores consultar que monto estaba vigente en que fecha específica.

Tipo 1:

- dim_source: Tiene los totales en obras financiadas y montos asignados que se actualizan al cambiar.
- dim_citizen: Almacena los datos actuales de los ciudadanos como sus nombres e identidades nacionales sin guardar datos anteriores para evitar riesgos.
- dim_proposal: Guarda los estados actuales de propuestas dadas por la ciudadanía

Tipo 0:

- dim_time: Catálogo de tiempo para fechas, años, etc.
- dim_event_type: Divide los 17 tipos de eventos de auditoría posibles dentro del sistema.

Y las tablas de hechos que identificamos fueron:

- fact_audit_events: Mide los eventos de auditoría como las acciones atómicas e inmutables sobre una obra.
- fact_work_monthly: Mide las obras por mes como una instantánea periódica del presupuesto, sus costos y sus avances.

Esas dos tablas de hechos se conectan con las dimensiones por claves subrogadas.

4. Qué preguntas concretas puede responder el sistema resultante.

El sistema que fue creado puede mostrar vistas analíticas y consultas estructuradas para responder preguntas como:

- ¿Cuáles obras presentas retrasos y de cuantos días de desfase acumularan?
- ¿Cómo clasifica y alerta que eventos de auditoria habrá según sus categorías como montos elevados, obras canceladas o modificación del presupuesto?
- ¿Cuál es el historial completo de una obra a lo largo del tiempo gracias a la trazabilidad SCD 2?
- ¿Cuál ha sido la ejecución del presupuesto acumulado que fue desglosado por fuente de financiamiento?
- ¿Cómo se distribuyen las propuestas de participación ciudadana según la región?

5. Qué limitaciones reconocen los autores y qué trabajo futuro proponen.

Algunas limitaciones que reconocen son por ejemplo que no existe un despliegue dinámico porque el sistema descansa sobre un artefacto estático y la API se ejecuta localmente, las votaciones de los participantes no representan a las minorías, su calidad depende de la calidad, cobertura y frescura en los supervisores en campo, los datos no han sido validados contra registros municipales por restricciones de privacidad, los extremos del mapa leen del esquema operacional y no de una vista de almacén eso puede generar divergencias y el acceso es ligero y carece de caducidad para tokens de sesión en los ciudadanos.

Y para un trabajo a futuro ellos proponen evolucionar la capa de objetos para que adopte un formato de tabla abierta para que sirva mediante motores ligeros, volverlo un canal de inferencia para computadora y así clasificar las obras por fotografías, publicar un vocabulario como si fuera un esquema para poder trabajar con datos enlazados, mejorar la votación cuadrática para mejorar a las propuestas minoritarias, agregar modelos de series temporales para fechas de finalización de obras y recomputar los criterios de anomalías de costo según su tipo de obra o validar las arquitecturas en distintos municipios.

BIBLIOGRAFÍAS

- Villa Vargas, J. M., Hurtado Avilés, G., y Climent Hernández, J. A. (2026). Cuando México tiembla: la historia contada por los datos. AZCATL Revista de Divulgación de la Ciencia, la Ingeniería y la Innovación, 4(6), 28–33. <https://doi.org/10.24275/AZC2026E1004>
- Velázquez Arrieta, E. U., Pulido Morales, O. F., García López, E., Hernández Martínez, C. A., y Hurtado Avilés, G. (en prensa). Territorial information retrieval from heterogeneous open data through the construction of a data warehouse for water management in Mexico City. En Advances in Computer Science Applications and Research. Springer.
- González Casiano, U., Maldonado Mejía, M. T., y Hurtado Avilés, G. (en prensa). A dimensional data warehouse for geospatial monitoring of municipal public works, with an evolution path toward a lakehouse architecture. En Advances in Computer Science Applications and Research. Springer.